

Analisi di metriche HR-derived per la stima dell'attivazione del guidatore nel pilot DistriMuSe P2-REGG: confronto tra approcci offline e runtime

Report tecnico

21 aprile 2026

1 Descrizione dei dati e del protocollo

1.1 Sessioni, percorsi e ordine sperimentale

Il confronto sperimentale rilevante è tra le condizioni D e ND. È essenziale ribadire che P1 e P2 sono percorsi, non condizioni di distrazione: non devono quindi essere interpretati come due livelli sperimentali alternativi al contrasto D/ND. La distinzione che conta per questa analisi è invece quella tra guida con distrazione e guida senza distrazione, ulteriormente scomposta per ordine di somministrazione delle sessioni, cioè soggetti *D-first* e soggetti *D-second*. I risultati finali mostrano in modo netto che quest'ultimo fattore influenza fortemente i valori osservati e l'interpretazione complessiva.

Il campione paired finale riportato nei file di sintesi comprende 42 soggetti canonici. Per l'analisi event-based il file `event_formula_summary.md` riporta 2452 eventi abbinati. L'intero report va quindi letto come analisi su un campione paired di 42 soggetti, con una scomposizione locale su eventi che mantiene lo stesso insieme canonico di soggetti ma aumenta il numero di osservazioni a livello di episodio.

1.2 Dati Coospo disponibili e problema della baseline

Le combinazioni finali salvate nel progetto sono tutte formulate a partire dalla frequenza cardiaca o da sue trasformazioni trasparenti. La criticità metodologica principale è che la baseline originaria di calibrazione non è stata salvata nei dati; di conseguenza l'analisi conclusiva non può usare come riferimento una misura di riposo iniziale osservata e persistita, ma soltanto surrogate baseline ricostruite a posteriori. Nei file finali queste surrogate compaiono come `session_local`, `baseline_invariant`, `first_sessionlow10median`, `first_sessionP10`, `first_sessionP20` e `first_sessionlower-quartilemedian`, oltre ad alcune ancore esplorative definite soltanto per soggetti con prima sessione ND.

Questa assenza non è un dettaglio tecnico minore. Se la baseline non è osservata direttamente, ogni differenza tra D e ND incorpora non solo la risposta locale al task o alla guida, ma anche drift inter-sessione, variabilità individuale e possibili effetti di ordine. I file finali mostrano infatti che cambiare baseline modifica in modo sensibile il numero di soggetti con $D > ND$, e che la baseline `first_session` tende a conservare meglio il contrasto offline mentre la baseline `session_local` tende ad assorbire parte del drift lento tra sessioni.

1.3 Definizione operativa delle metriche e delle baseline

Per evitare che i nomi compatti usati nei file finali risultino opachi, conviene fissare una notazione minima. Indichiamo con $HR(t)$ la frequenza cardiaca osservata al tempo t , con b la baseline usata come riferimento, con $\overline{HR}_W$ la media dell'HR in una finestra temporale W e con S_1 la prima sessione valida del soggetto. Quando nei file finali non è riportata la formula implementativa completa, nel seguito si usa una scrittura schematica, sufficiente però a chiarire il significato operativo della metrica.

Che cosa si intende per baseline. In questo report la baseline è il valore di riferimento rispetto al quale si misura lo scostamento dell'HR. In forma elementare, una metrica basata su baseline lavora su quantità del tipo $HR(t) - b$ oppure $(HR(t) - b)/b$. Questo significa che la stessa serie HR può produrre risultati diversi se cambia il riferimento b . È quindi utile distinguere tre casi concettualmente diversi. Una *baseline offline storica* è calcolata a partire da una sessione già disponibile del soggetto, per esempio la prima sessione valida; in forma schematica si può scrivere $b_{\text{hist}} = h(S_1)$, dove h è una statistica robusta della distribuzione HR della prima sessione. Una *baseline locale di sessione* è invece stimata usando solo dati della sessione corrente già osservati al momento del calcolo, quindi in forma causale: $b_{\text{loc}}(t) = h(\{HR(\tau) : \tau \leq t\})$. Infine, la *baseline di calibrazione originale* è quella che sarebbe stata ottenuta nella fase di calibrazione iniziale del dispositivo o del protocollo; il report la richiama per chiarezza metodologica, ma non può riutilizzarla perché non è stata salvata nei dati finali.

La differenza operativa tra questi tre casi è essenziale. La baseline offline storica può essere molto utile per l'analisi a posteriori, perché conserva il contrasto fra sessioni e rende più visibile la differenza D/ND; proprio per questo, però, non è disponibile in senso stretto durante il runtime della singola sessione. La baseline locale di sessione è invece adatta al runtime, perché usa soltanto informazione già osservata nella sessione corrente, ma tende anche ad assorbire una parte del drift lento intra- o inter-sessione. La baseline di calibrazione originale sarebbe stata il riferimento metodologicamente più diretto verso la formula legacy, ma non è ricostruibile dai file finali salvati.

Metriche principali. `hr_mean` è la media dell'HR sull'intera sessione. In forma semplice,

$$\overline{HR}_{\text{session}} = \frac{1}{N} \sum_{i=1}^N HR_i.$$

La sua interpretazione è immediata: descrive il livello medio di frequenza cardiaca nella sessione. È una metrica di stato lento, utile come riferimento globale, ma non isola in modo specifico le variazioni transitorie legate a singoli episodi di task.

`delta_hr_mean_from_baseline` misura di quanto la media della sessione si sposta rispetto a una baseline scelta. In forma semplice,

$$\Delta \overline{HR} = \overline{HR}_{\text{session}} - b.$$

Se il valore è positivo, la sessione si colloca in media sopra la baseline; se è negativo, sotto. È quindi una metrica di attivazione globale, ancora di tipo session-level, che traduce il livello medio della sessione in uno scostamento rispetto a un riferimento esplicito.

`hr_burden_above_baseline_plus_3bpm` non misura la media dell'HR, ma la quota di campioni in cui l'HR supera la baseline di almeno 3 bpm. In forma schematica,

$$\text{burden}_{+3} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[HR_i > b + 3].$$

Questa definizione va letta in modo molto concreto: il valore della metrica è la frazione, o percentuale, del tempo campionato in cui il soggetto si trova oltre la soglia *baseline + 3 bpm*. Intuitivamente, non descrive quanto l'HR sia alta in media, ma quanto a lungo rimanga sopra un livello considerato operativamente più attivato rispetto al riferimento.

A2 è un indice composito session-level. Nei file finali viene trattato come benchmark di stato lento, non come indice locale per effetti di pochi secondi. Quando non si entra nel dettaglio implementativo, la sua logica si può esprimere in forma schematica come

$$A2 = \text{Agg}_{t \in \text{sessione}} \psi \left(\frac{HR(t) - b}{b} \right),$$

dove ψ rappresenta una trasformazione dello scostamento normalizzato dalla baseline e Agg una aggregazione sull'intera sessione. L'interpretazione intuitiva è che **A2** non fotografa un singolo evento, ma riassume quanto e come la sessione nel suo complesso si discosti dal riferimento; per questo è più adatto come descrittore di stato lento che come indicatore di transient effects. In termini qualitativi, **A2** combina una misura di scostamento medio dalla baseline con una misura di permanenza sopra soglia e una componente legata al livello minimo locale dell'HR; per questo viene usato come benchmark session-level di stato lento e non come indice principale degli effetti transitori.

E1 è una metrica locale, costruita attorno a un evento. A livello di singolo episodio confronta una finestra immediatamente precedente all'evento con una finestra immediatamente successiva, combinando una differenza media pre/post con una misura di permanenza sopra soglia. In forma schematica, a livello di evento,

$$E1_{\text{event}} \approx 0.7 (\overline{HR}_{\text{post}} - \overline{HR}_{\text{pre}}) + 0.3 \text{burden}_{\text{post}}.$$

Nel report, i valori finali associati a **E1** non coincidono con il singolo punteggio di evento, ma derivano da una successiva aggregazione sui diversi episodi osservati per soggetto e sessione, con confronto finale tra eventi di task e controlli abbinati. L'interpretazione intuitiva resta comunque semplice: **E1** misura se, attorno a un episodio di task, l'HR tende localmente ad aumentare rispetto al riferimento pre-evento.

E3 parte dalla stessa logica locale di **E1**, ma aggiunge una componente dinamica legata alla rapidità con cui l'HR sale o scende attorno all'evento. In forma schematica, a livello di episodio,

$$E3_{\text{event}} \approx E1_{\text{event}} + \lambda \Delta \text{slope},$$

dove Δslope rappresenta una differenza di pendenza locale tra la fase post-evento e la fase pre-evento, e λ indica il peso assegnato alla componente dinamica. Anche in questo caso i risultati finali riportati nel report sono ottenuti dopo aggregazione sui diversi eventi del soggetto. L'interpretazione intuitiva è che **E3** non guarda solo al salto medio dell'HR, ma anche alla forma temporale della risposta.

Baseline usate nei file finali. Nel report, `session_local` va intesa come una baseline causale aggiornata a partire dai dati già osservati nella sessione corrente; la statistica precisa usata per

costruirla può variare tra le diverse implementazioni, ma il principio rimane quello di non usare mai informazione futura. In forma schematica,

$$b_{\text{session_local}}(t) = h(\{HR(\tau) : \tau \leq t, \tau \in \text{sessione corrente}\}).$$

Il punto metodologico non è tanto la statistica precisa h , quanto il fatto che il riferimento viene costruito localmente e in tempo reale. Per questo `session_local` è la scelta naturale per il runtime, ma tende anche ad assorbire una parte dei drift lenti che offline potrebbero invece contribuire al contrasto D/ND.

`first_sessionlower-quartilemedian` è la mediana del 25% più basso dei valori HR osservati nella prima sessione valida del soggetto. Se $Q_{25}(S_1)$ è il primo quartile della distribuzione HR della prima sessione, allora si può scrivere

$$b_{LQ} = \text{median}\{HR_i \in S_1 : HR_i \leq Q_{25}(S_1)\}.$$

Metodologicamente questa baseline cerca un riferimento basso ma robusto, meno sensibile di un singolo percentile estremo e più stabile di un minimo grezzo. È una baseline offline storica: utile per analisi a posteriori, ma non direttamente utilizzabile come riferimento causale nella sessione corrente.

`first_sessionlow10median` è la mediana del 10% più basso dei valori HR della prima sessione valida. In forma schematica,

$$b_{\text{low10}} = \text{median}\{HR_i \in S_1 : HR_i \leq Q_{10}(S_1)\}.$$

Rispetto alla versione lower-quartile, questa baseline seleziona una coda più stretta e più bassa della distribuzione HR, quindi può enfatizzare maggiormente uno stato “basso” del soggetto, al prezzo di una maggiore sensibilità alla scelta del percentile.

`first_sessionP10` e `first_sessionP20` sono invece direttamente i percentili della distribuzione HR della prima sessione valida:

$$b_{P10} = Q_{10}(S_1), \quad b_{P20} = Q_{20}(S_1).$$

Sono definizioni più semplici e più immediate delle versioni “median of the lower tail”, ma proprio perché usano un singolo percentile possono essere più sensibili alla forma della distribuzione della prima sessione. Restano comunque baseline offline storiche e non riferimenti causali di runtime.

`baseline_invariant` significa, operativamente, che la metrica non dipende da alcuna baseline esplicita. In questi casi la formula usa direttamente i valori HR o una loro aggregazione, senza un termine b . Metodologicamente questo elimina la dipendenza dalla scelta del riferimento, ma non risolve da solo il problema della separazione D/ND: semplicemente sposta l’attenzione dalla scelta della baseline alla capacità della metrica di cogliere il contrasto nei dati grezzi o nelle loro aggregate.

Collegamento con la formula legacy. È utile distinguere con chiarezza la formula legacy di arousal usata durante i test dalle metriche HR-derived trasparenti adottate nel report finale. Nel codice originale, la baseline HR era definita come media dei valori di HR durante la fase di calibrazione,

$$b_{\text{cal}} = \frac{1}{N_{\text{cal}}} \sum_{i=1}^{N_{\text{cal}}} HR_i^{\text{cal}}.$$

Il ramo HR della formula legacy usava poi una quantità del tipo

$$r_{\text{HR}}(t) = \frac{|HR(t) - b_{\text{cal}}|}{b_{\text{cal}}},$$

che veniva successivamente normalizzata usando il minimo e il massimo osservati in calibrazione,

$$\tilde{r}_{\text{HR}}(t) = \frac{r_{\text{HR}}(t) - r_{\text{cal}}^{\min}}{r_{\text{cal}}^{\max} - r_{\text{cal}}^{\min}}.$$

Le metriche finali del report non sono quindi repliche esatte del legacy arousal. Sono surrogate trasparenti, costruite per preservare un significato operativo leggibile anche in assenza della baseline di calibrazione originaria e delle relative informazioni di normalizzazione. Questo è il motivo per cui nel report si parla di proxy HR-derived di attivazione e non di riproduzione fedele dell'indice legacy.

Tabella 1: Mini-glossario operativo delle metriche e delle baseline richiamate nel report.

Termine	Significato operativo
<code>hr_mean</code>	Media dell'HR sull'intera sessione; descrive un livello medio di stato lento senza introdurre una baseline esplicita.
<code>delta_hr_mean_from_baseline</code>	Scostamento tra media HR della sessione e baseline scelta; indica se la sessione è, in media, sopra o sotto il riferimento.
<code>hr_burden_above_baseline_plus_3bpm</code>	Frazione di campioni in cui l'HR supera <i>baseline + 3 bpm</i> ; misura per quanto tempo il segnale resta sopra una soglia di attivazione locale.
<code>A2</code>	Indice composito session-level che aggrega lo scostamento dall'HR di riferimento lungo tutta la sessione; utile come benchmark di stato lento.
<code>E1</code>	Indice locale/event-based basato sul confronto pre/post evento e sul confronto con eventi di controllo abbinati; candidato principale per il runtime.
<code>E3</code>	Variante locale di <code>E1</code> che aggiunge una componente dinamica di pendenza; utile come alternativa più sensibile alla forma temporale della risposta.
<code>session_local</code>	Baseline causale ricavata dalla sessione corrente usando solo dati già osservati; adatta al runtime ma più incline ad assorbire il drift lento.
<code>first_sessionlower-quartilemedian</code>	Mediana del 25% più basso dei valori HR della prima sessione valida; baseline offline storica, robusta e non direttamente runtime-ready.

La Tabella 1 fornisce una sintesi rapida, ma il punto metodologico da trattenere è più generale: una metrica di attivazione offline, una metrica di attivazione runtime e una baseline di riferimento non sono oggetti intercambiabili. Nei paragrafi successivi i nomi brevi delle metriche vanno quindi letti come etichette operative di costruzioni diverse: alcune riassumono uno stato medio di sessione, altre descrivono una variazione locale attorno a un evento, altre ancora definiscono il riferimento rispetto al quale si misura lo scostamento dell'HR. Per chiarezza, `hr_mean` e `delta_hr_mean_from_baseline` sono espressi in bpm; `hr_burden_above_baseline_plus_3bpm` è una frazione adimensionale compresa tra 0 e 1; `E1`, `E3` e `A2` sono punteggi compositi senza un'unità fisica diretta.

1.4 Perché RR non è stato mantenuto come componente primaria

Nel materiale finale del progetto le metriche raccomandate non sono costruite su RR come componente primaria, ma su HR e su differenze rispetto a baseline trasparenti. La ragione,

in questo report, non viene formulata come una tesi generale sull'inutilità di RR, bensì come una prudenza specifica del dataset disponibile: manca la baseline originaria di calibrazione, le raccomandazioni finali convergono tutte su proxy HR-derived, e i file salvati non offrono una catena conclusiva altrettanto chiara e robusta per una soluzione primaria basata su RR. Per questo le conclusioni operative vengono espresse solo in termini di metriche HR-derived di attivazione.

2 Evoluzione dell'analisi

L'analisi è evoluta in tre passaggi principali. In primo luogo è stata accantonata l'idea di usare un arousal black-box proprietario come asse conclusivo. Un indice non trasparente può essere utile in fase esplorativa, ma non è adeguato come risultato finale da discutere con partner e revisori se non è ricostruibile e interpretabile nei suoi componenti.

In secondo luogo sono state costruite metriche trasparenti basate su HR. A livello session-level i file finali confrontano, fra le altre, combinazioni come `hr_mean`, `delta_hr_mean_from_baseline`, `A2` e `hr_burden_above_baseline_plus_3bpm`. Queste metriche sono state valutate sia rispetto alla loro interpretabilità sia rispetto alla capacità di produrre, per ogni soggetto, un delta D–ND con prevalenza positiva.

In terzo luogo l'analisi è stata portata su scala locale, attorno agli episodi di task SURT, introducendo formule event-based E1, E2, E3 ed E4 e confrontando diverse finestre temporali. In questa fase l'obiettivo non è più descrivere uno stato lento di sessione, ma catturare transient effects in prossimità dell'evento. La scelta finale è stata poi sottoposta a un test di robustezza semplice ma severo: quanti soggetti mostrano $D > ND$, e quanto questo risultato rimane stabile quando si separano i sottogruppi *D-first* e *D-second*.

Il criterio conclusivo adottato dai file finali è particolarmente utile perché impedisce di nascondere i risultati negativi dietro a sole medie aggregate. Il file `final_subjectcount_summary.md` definisce infatti un target forte di almeno 30/40 soggetti positivi senza collasso dei sottogruppi. Questo target non viene raggiunto da nessuna combinazione, e proprio questa mancata convergenza è la chiave interpretativa del report.

3 Risultati principali: soluzione offline

Il principale risultato positivo del pilot, in termini di recupero del contrasto D/ND, resta la combinazione `hr_burden_above_baseline_plus_3bpm` con baseline `first_lower_quartile_median`, etichettata nel report come *first-session lower-quartile median*. Il file `final_metric_baseline_recommendation.csv` la individua come combinazione con il più alto numero di soggetti positivi, e nel file `final_subjectcount_ranking.csv` essa totalizza 28 soggetti con $D > ND$ su 42, cioè il 66,7% del campione, con *binomial p-value* complessivo pari a 0,0218 rispetto al riferimento 0,5, media D–ND pari a 0,0983, mediana 0,0711 e Cohen d_z pari a 0,3327.

Il risultato è il migliore esito ottenuto nel campione in termini di prevalenza soggettuale e di recupero offline del contrasto D/ND, ma non è sufficiente a una dimostrazione forte. In termini assoluti, 28/42 rimane sotto il target forte 30/40; inoltre il campo `count_gap_to_target_30` segnala esplicitamente che mancano due soggetti alla soglia nominale di 30 positivi. Ancora più importante, la stessa riga di ranking classifica il risultato come *weak / order-sensitive*. Il miglior conteggio offline non è dunque un esito robusto nel senso richiesto dal progetto.

La ragione emerge con chiarezza quando si scompone il campione per ordine di sessione. Nei soggetti *D-first* la combinazione migliore offline produce 19 positivi su 20, cioè il 95,0%, con *binomial p-value* pari a $2,0 \times 10^{-5}$ e media D–ND pari a 0,2770. Nei soggetti *D-second*, invece, la stessa metrica scende a 9 positivi su 22, cioè il 40,9%, con *binomial p-value* pari a 0,8569 e media D–ND negativa, pari a –0,0642. La differenza tra i due sottogruppi, misurata dal campo *subgroup_imbalance*, è 0,5409. In forma più sintetica: circa 95% di positivi in *D-first* contro circa 41% in *D-second*.

Il confronto tra file finali mostra anche un punto sottile ma importante. Nelle prime posizioni di *final_subjectcount_ranking.csv* compaiono più combinazioni a quota 28/42, in particolare diverse varianti di *A_anchor* con baseline di prima sessione. Non si tratta di una contraddizione, ma di un ex aequo sul conteggio grezzo. Il file *final_metric_baseline_recommendation.csv*, che ha il ruolo più chiaramente prescrittivo, scioglie l'ex aequo a favore di *hr_burden_above_baseline_plus_3bpm* con *first_sessionlower-quartilemedian*; nel presente report viene quindi adottata questa coppia come soluzione offline principale.

Il file *baseline_variant_comparison.csv* conferma che il vantaggio offline dipende in larga misura dalla famiglia di baseline usata. Le ancore simmetriche di prima sessione raggiungono 27 o 28 soggetti positivi, mentre le opzioni *session_local* e *baseline_invariant* si fermano a 26/42. Le ancore favorevoli *ND-first* non sono comparabili sull'intero campione e rimangono esplicitamente marcate come esplorative o non robuste. La conclusione operativa è quindi chiara: la migliore soluzione offline resta il principale risultato positivo del report, utile per validazione a posteriori e per il recupero del contrasto D/ND, ma non è runtime-ready e non è robusta rispetto all'ordine. La soluzione runtime discussa nella sezione seguente va letta come un compromesso metodologicamente più causale e locale, ma meno forte sul piano dell'evidenza.

Una lettura complementare, soggetto per soggetto, è fornita dalla Figura 1, che rende visibile come il risultato offline principale sia presente in una maggioranza dei casi ma non in modo uniforme nell'intero campione.




Figura 1: Ranking dei delta paired D–ND a livello soggetto per la migliore soluzione offline, ottenuta con la metrica *hr_burden_above_baseline_plus_3bpm* e baseline *first-sessionlower-quartilemedian*. L'ordinamento è decrescente sui delta individuali; i soggetti con delta positivo sono 28 su 42.

La figura ordina i soggetti in base al delta paired D–ND della migliore metrica offline e rende immediatamente leggibile l'eterogeneità inter-soggetto del risultato. Le barre arancioni corrispondono ai soggetti con delta positivo, mentre le barre blu rappresentano i soggetti con delta negativo; l'ordinamento decrescente mostra con chiarezza che il contrasto offline è presente in

una maggioranza dei soggetti, ma non in tutti. La presenza di diversi casi con delta vicino a zero o negativo conferma che il segnale, pur essendo il migliore ottenuto offline, non realizza una separazione forte e generalizzabile per tutto il campione. In questo senso la figura rafforza la lettura del risultato principale offline, ma non elimina il problema della sensibilità all'ordine che emerge nella successiva scomposizione per sottogruppi.

La rappresentazione grafica di questo quadro è raccolta anche nelle Figure 2–5; la sintesi numerica è riportata nelle Tabelle 2 e 3.

4 Risultati principali: soluzione runtime

La parte runtime va letta come un secondo livello di analisi: non fornisce il risultato positivo principale del pilot, ma identifica il miglior compromesso causale e locale oggi disponibile. Per un uso runtime la baseline deve essere causale e adattiva. Per questo motivo le baseline locali di sessione sono concettualmente più adatte delle baseline ancorate a una sessione storica. Il prezzo da pagare è che una baseline `session_local` tende ad assorbire parte del drift lento fra sessioni e quindi, come mostrano i file finali, riduce spesso la prevalenza grezza $D > ND$ rispetto alle migliori soluzioni offline. Tuttavia questa perdita di conteggio è il costo di una scelta metodologicamente più credibile per uso online.

In questo quadro la soluzione raccomandata per il runtime è E1 con baseline `session_local`. Il file `final_metric_baseline_recommendation.csv` la segnala sia come `best_order_balanced` sia come `best_runtime_usable`. Nel file `final_subjectcount_ranking.csv` la combinazione E1|`session_local` raggiunge 24 positivi su 42, pari al 57,1%, con media $D-ND$ 0,0191, mediana 0,0112, Cohen d_z 0,1014 e *binomial p-value* complessivo 0,2204. Il punto decisivo, però, è l'equilibrio per ordine: 11/20 positivi in *D-first* (55,0%) contro 13/22 in *D-second* (59,1%), con `subgroup_imbalance` pari a 0,0409. Il conteggio è inferiore a quello offline, ma la dipendenza dall'ordine è molto più contenuta.

Il file `event_formula_by_order.csv` conferma questo giudizio anche sul piano dei delta medi per sottogruppo. Per E1 la media task-control è 0,0518 in *D-first* con *paired t-test* $p = 0,3040$, mentre in *D-second* è $-0,0105$ con $p = 0,7552$: non c'è una inversione forte del segno, ma piuttosto una forte attenuazione verso la neutralità. È precisamente questa attenuazione, più che un apparente incremento medio, a rendere E1 la formula locale più credibile come proxy runtime di attivazione.

La formula secondaria è E3. Il file `event_formula_recommendation.csv` la definisce *secondary dynamic alternative*. Anche E3|`session_local` totalizza 24/42 positivi, con media $D-ND$ 0,0154, mediana 0,0204 e Cohen d_z 0,1102. Nel file `event_formula_by_order.csv` E3 mostra una differenza leggermente più piccola tra le medie dei sottogruppi (campo `order_gap_abs` pari a 0,0401 contro 0,0622 per E1), ma nel ranking finale di prevalenza E1 resta preferibile perché più interpretabile. E3 va quindi letta come complemento utile, non come asse centrale del report.

Il benchmark A2 va mantenuto, ma solo come riferimento session-level. I file `event_formula_summary.md` e `event_formula_recommendation.csv` riportano per il benchmark sessionale un mean $D-ND$ pari a $-7,449$. La riga A2|`session_local` di `final_subjectcount_ranking.csv` mostra inoltre appena 11 positivi su 42 (26,2%), mediana $-7,1322$ e Cohen $d_z = -0,5258$. In altri termini, A2 resta utile come termine di paragone di stato lento, ma non emerge come migliore indice locale.

Per quanto riguarda la finestra temporale, il file `event_window_comparison.csv` raccomanda

la finestra *immediate post* [0s, +10s]. Su 42 soggetti questa finestra produce, nel confronto pre/post interno alla condizione D, una media pari a 0,0151, mediana 0,0290, *paired t-test* $p = 0,6470$, *Wilcoxon* $p = 0,8625$, Cohen $d_z = 0,0712$ e 59,5% di soggetti positivi. La finestra *delayed post* non migliora il segnale, mentre la finestra *during* mostra una media interna più alta (0,1334) ma su 41 soggetti e con una comparabilità peggiore, perché le durate degli eventi variano sensibilmente. Per il runtime, la raccomandazione finale è quindi mantenere [0, +10] s come compromesso migliore fra causalità, tempestività e confrontabilità.

Anche per la soluzione runtime la conclusione deve rimanere prudente. E1 è la migliore scelta locale e causale oggi disponibile nel progetto, ma non costituisce una misura validata di arousal; è piuttosto un indice locale di attivazione utile come miglior compromesso runtime, sostenuto però da un'evidenza più debole del risultato offline principale. Le Figure 6–10 e la Tabella 4 rendono visibile questo compromesso tra interpretabilità, debolezza dell'effetto e relativa tenuta all'ordine.

5 Proiezione della metrica offline sui log SURT

Questa sezione non introduce una nuova metrica candidata, ma mostra come la migliore metrica offline possa essere proiettata sui log SURT come annotazione derivata. Il punto metodologico da fissare subito è che i log SURT originali non sono stati modificati: i file sorgente sono stati preservati invariati, mentre la procedura finale ha prodotto un nuovo export arricchito in cui ai record originali sono stati affiancati campi derivati. In questo senso, la proiezione non sostituisce l'informazione originaria presente nei log e non rimpiazza alcun indice precedente; aggiunge piuttosto una annotazione offline-derived di attivazione, costruita a partire dalla migliore metrica offline individuata nel report, cioè `hr_burden_above_baseline_plus_3bpm` con baseline *first-session lower-quartile median*.

Dal punto di vista operativo, l'export arricchito associa a ciascun soggetto e ai relativi eventi SURT un riferimento fisiologico coerente con l'analisi offline globale. Il campo `baseline_first_session_lqm` rappresenta il valore soglia soggetto-specifico ricavato come mediana del 25% più basso dei valori HR della prima sessione valida. Il campo `hr_burden_above_baseline_plus_3bpm_session` è la versione fedele della metrica offline a livello di sessione, mentre `hr_burden_above_baseline_plus_3bpm_session_100` ne è la stessa quantità espressa su scala 0–100. Accanto a questi campi globali compaiono i corrispondenti campi locali `hr_burden_above_baseline_plus_3bpm_rol120` e `hr_burden_above_baseline_plus_3bpm_rol120_100`, che leggono la stessa logica di burden HR-derived in una finestra causale mobile di 20 secondi centrata sul contesto temporale del log. In altre parole, il campo `session` serve a conservare la metrica offline fedele a livello di sessione, mentre il campo `rol120` funziona come proxy locale offline proiettato sui log SURT e permette di interpretare ogni riga del log in chiave fisiologica senza alterare il dato originale. I campi `hr_rol120_valid_sample_count` e `hr_rol120_coverage_ratio` hanno invece un ruolo diagnostico: indicano rispettivamente quanti campioni HR validi entrano nella finestra locale di 20 secondi e quale quota della finestra dispone di copertura utilizzabile. I file di sintesi finali non riportano una statistica dedicata per questi due campi, ma la loro funzione metodologica è chiaramente quella di documentare la qualità locale dell'annotazione fisiologica.

I file di sintesi mostrano che questa proiezione preserva il contrasto globale osservato offline. Il file `surt_offline_activation_summary.md` riporta che il burden di sessione mantiene 28 soggetti su 42 con $D > ND$, con mean delta pari a 0,0984; lo stesso conteggio 28/42 riemerge anche quando si usano, per ogni soggetto, le medie di sessione della annotazione locale `rol120`, con

mean delta pari a 0,1118. I valori puntuali sono confermati dal file `surt_offline_activation_stats.csv`, che per `hr_burden_above_baseline_plus_3bpm_session` riporta $n = 42$, *paired t-test* $p = 0,0368$, *Wilcoxon* $p = 0,0916$, Cohen $d_z = 0,3331$ e 28 soggetti positivi, mentre per `mean_roll120_burden` riporta ancora $n = 42$, *paired t-test* $p = 0,0267$, *Wilcoxon* $p = 0,0638$, Cohen $d_z = 0,3547$ e 28 soggetti positivi. In termini pratici, la proiezione sui log SURT non peggiora il contrasto globale: la versione locale `roll120`, una volta riassunta a livello di sessione, resta coerente con la metrica offline principale.

Il file di sintesi finale riporta inoltre 2713 righe SURT reali arricchite e 2713 pseudo-righe ND matched usate per il confronto locale. Questo conteggio descrive l'export arricchito complessivo. I file statistici locali lavorano però su sottocampioni più piccoli: `surt_offline_activation_stats.csv` usa 2697 righe D e 2557 righe ND per la distribuzione row-level del `roll120`, mentre l'associazione con `ResponseTime_ms` è calcolata su 2470 righe D. Poiché i file disponibili non esplicitano il dettaglio di ogni filtro intermedio, nel presente report si adotta 2713/2713 come conteggio dell'export arricchito finale e si leggono i conteggi inferiori come subset analitici verosimilmente determinati da disponibilità della variabile o da requisiti di validità e copertura locale.

La scomposizione per ordine mostra che la proiezione SURT non risolve il problema principale già emerso nell'analisi offline generale. Nel file `surt_offline_activation_by_order.csv`, il burden di sessione mantiene 19 positivi su 20 in *D-first* con mean delta 0,2776, ma scende a 9 positivi su 22 in *D-second* con mean delta $-0,0645$. Lo stesso schema si ripete quasi identico per la media di sessione del `roll120`: 19/20 in *D-first* con mean delta 0,3007 contro 9/22 in *D-second* con mean delta $-0,0599$. La proiezione sui log è quindi coerente con il contrasto offline, ma rimane fortemente sensibile all'ordine delle sessioni; in questo senso aggiunge leggibilità locale ai log SURT, senza sciogliere il limite strutturale del dataset.

L'aspetto più rilevante, però, emerge quando si guarda il segnale nel tempo attorno all'evento. Il file `surt_roll120_prepost_stats.csv` mostra un effetto pre/post molto piccolo: nella condizione D il burden locale medio passa da 0,4117 a 0,4131, con variazione media post-pre pari a 0,0006, *paired t-test* $p = 0,8662$ e Cohen $d_z = 0,0032$; nella condizione ND il burden passa da 0,3089 a 0,3067, con variazione media $-0,0024$, *paired t-test* $p = 0,4780$ e Cohen $d_z = -0,0140$. Questo quadro suggerisce che la differenza tra D e ND si manifesti più come uno scarto di livello locale persistente che come una risposta cardiaca impulsiva, chiaramente agganciata al singolo evento SURT. Tale lettura è coerente con la natura breve del task e con le caratteristiche del sensore: se il compito è intermittente e il segnale HR è relativamente lento, la metrica può cogliere meglio un contesto locale più "alto" di attivazione che non un picco netto e strettamente event-locked.

Anche il legame con la performance SURT va quindi interpretato con prudenza. Nel file `surt_offline_activation_stats.csv` l'associazione tra `hr_burden_above_baseline_plus_3bpm_roll120` e `ResponseTime_ms` nelle righe D reali è debole (Spearman $\rho = -0,0354$, $p = 0,0789$, $n = 2470$), cioè non mostra una struttura forte o un chiaro gradiente monotono. L'associazione con `error_flag` è positiva ma piccola ($\rho = 0,0774$, $p = 5,7 \times 10^{-5}$, $n = 2697$), mentre quella con `timeout_flag` resta debole e non convincente ($\rho = 0,0233$, $p = 0,2262$). Questi risultati non autorizzano quindi a descrivere la metrica come surrogato diretto della performance SURT: al massimo suggeriscono una relazione fisiologica debole, locale e rumorosa, che non si traduce in una proxy prestazionale lineare.

Va inoltre esplicitato un limite specifico di questa parte dell'analisi. I veri log SURT esistono soltanto nelle sessioni D; per costruire un confronto locale con ND è stato quindi necessario usare pseudo-eventi matched agli stessi offset temporali nella sessione ND paired. Questo approccio è metodologicamente utile, perché preserva l'allineamento temporale e consente un controllo

causale minimale del contesto, ma non produce un confronto tra eventi SURT reali omologhi in D e ND. La lettura locale va quindi presentata per quello che è: un confronto con matched offsets, non una dimostrazione di risposta evento-specifica perfettamente simmetrica fra condizioni.

Nel complesso, questa proiezione supporta una conclusione prudente ma utile. La migliore metrica offline può essere proiettata con coerenza sui log SURT come annotazione derivata, e la versione `roll20` costituisce una annotazione locale offline-derived leggibile e coerente con il contrasto globale D/ND. Tuttavia il segnale locale osservato sembra descrivere soprattutto una differenza di livello contestuale persistente, più che una risposta cardiaca impulsiva netta e strettamente agganciata al singolo evento; inoltre il problema dell'ordine delle sessioni rimane sostanzialmente irrisolto. La proiezione SURT va quindi letta come estensione interpretativa della soluzione offline, non come sostituzione del confronto principale tra approcci offline e runtime. La Figura 11 riassume visivamente questi punti.

6 Statistiche da riportare

Le Tabelle 2–4 raccolgono le statistiche principali disponibili nei file finali. Dove una statistica non è presente nei file sorgente, viene indicata come non disponibile invece di essere ricostruita a posteriori.

Tabella 2: Prevalenza soggettuale $D > ND$ per le combinazioni chiave. L'*imbalance* è la differenza assoluta tra le proporzioni positive nei sottogruppi D-first e D-second.

Ruolo	Livello	Metrica	Baseline	Positivi	D-first	D-second	Imbalance
Migliore offline	sessione	<code>hr_burden_above_baseline_plus_3bpm</code>	first-session quartile median	28/42 (66,7%)	19/20 (95,0%)	9/22 (40,9%)	0,5409
Migliore runtime	evento	E1	<code>session_local</code>	24/42 (57,1%)	11/20 (55,0%)	13/22 (59,1%)	0,0409
Secondaria runtime	evento	E3	<code>session_local</code>	24/42 (57,1%)	10/20 (50,0%)	14/22 (63,6%)	0,1364
Benchmark session-level	sessione	A2	<code>session_local</code>	11/42 (26,2%)	2/20 (10,0%)	9/22 (40,9%)	0,3091

Tabella 3: Misure d'effetto e p-value disponibili per le combinazioni chiave. I p-value paired t-test per E1 ed E3 sono disponibili solo nel file `by-order`, quindi sono riportati per sottogruppo.

Ruolo	Mean D–ND	Median D–ND	Cohen d_z	p binomiale compl.	p binomiale D-first / D-second	p paired t-test D-first / D-second	Nota
Migliore offline	0,0983	0,0711	0,3327	0,0218	$2,0 \times 10^{-5}$ / 0,8569	n.d. / n.d.	combinazione offline-only
Migliore runtime E1	0,0191	0,0112	0,1014	0,2204	0,4119 / 0,2617	0,3040 / 0,7552	migliore compromesso causale
Secondaria runtime E3	0,0154	0,0204	0,1102	0,2204	0,5881 / 0,1431	0,3371 / 0,8784	alternativa dinamica
Benchmark A2	–7,4494	–7,1322	–0,5258	0,9995	0,99998 / 0,8569	n.d. / n.d.	benchmark session-level

Tabella 4: Confronto tra finestre temporali per l'analisi locale. I test riportati nel file `event_window_comparison.csv` sono interni alla condizione D o al matched control, non un test finale diretto D vs ND.

Finestra	Etichetta	n	Mean within-D	Median within-D	p paired t	p Wilcoxon	d_z	% positivi within-D	Mean control matched	Nota
<code>immediate_post</code>	[0 s, +10 s]	42	0,0151	0,0290	0,6470	0,8625	0,0712	59,5%	0,0289	miglior compromesso causale e operativo
<code>delayed_post</code>	[+5 s, +15 s]	42	0,0168	0,0209	0,7488	0,9212	0,0497	52,4%	0,0201	non migliora il segnale
<code>during</code>	[0 s, fine evento]	41	0,1334	0,0559	0,3355	0,3575	0,1523	53,7%	0,0800	media più alta ma minore comparabilità

Per E1 ed E3 i file finali non riportano un paired t-test complessivo o un test di Wilcoxon complessivo D vs ND sulla metrica finale di prevalenza; riportano invece la media D–ND, Cohen d_z , il conteggio dei soggetti positivi e i paired t-test separati per ordine nel file `event_formula_by_order.csv`. Allo stesso modo, `event_window_comparison.csv` documenta la qualità relativa delle finestre temporali con test pre/post interni, non con un test finale unico D vs ND. Queste assenze non vengono colmate artificialmente in questo report.

7 Discussione

Letti nel loro insieme, i risultati definiscono una gerarchia abbastanza netta. Primo, esiste un risultato offline utile e quantitativamente migliore nel recupero del contrasto D/ND, anche se fortemente sensibile all'ordine delle sessioni. Secondo, esiste una soluzione runtime più equilibrata e più causale, ma sostenuta da un segnale complessivamente più debole. Terzo, la proiezione SURT aggiunge leggibilità locale alla soluzione offline senza modificare questa gerarchia di fondo.

7.1 Perché la baseline incide così tanto

I file finali mostrano che la baseline è una variabile strutturale dell'analisi, non un semplice dettaglio di normalizzazione. La baseline `session_local` è metodologicamente appropriata per il runtime perché è causale e aggiorna il riferimento all'interno della stessa sessione; proprio per questo, però, tende ad assorbire il drift lento inter-sessione e a ridurre il contrasto complessivo $D > ND$. Le baseline `first_session`, invece, preservano meglio il contrasto offline perché usano un riferimento storico esterno alla sessione corrente. Il confronto tra famiglie di baseline chiarisce quindi un punto essenziale: una baseline più favorevole può far crescere il conteggio dei soggetti positivi, ma questo non rende automaticamente il risultato robusto né generalizzabile.

7.2 Perché offline e runtime devono essere separati

I risultati numerici rendono improprio cercare una formula unica ottima per tutto. Il recupero più forte del contrasto avviene offline: in questo regime è legittimo usare un riferimento storico del soggetto, purché si espliciti che si tratta di un'analisi a posteriori e non causale, e la combinazione migliore arriva a 28/42. Runtime, invece, richiede una baseline disponibile in tempo reale, quindi causale e adattiva; in questo regime la soluzione più credibile scende a 24/42 ma resta molto più equilibrata tra D-first e D-second. La divergenza tra queste due soluzioni non è un fallimento dell'analisi: è il risultato atteso quando si separano correttamente validazione offline e monitoraggio online.

7.3 Che cosa dimostrano davvero questi risultati

Questi risultati non dimostrano che l'attivazione sia sempre maggiore in D che in ND, né autorizzano a presentare la metrica finale come arousal validato. Dimostrano però tre cose più circoscritte e metodologicamente difendibili. La prima, e più importante nel quadro del pilot, è che alcune metriche HR-derived riescono a recuperare offline un contrasto utile fra D e ND se si usa una baseline storica favorevole ma simmetrica. La seconda è che un indice locale/event-based, soprattutto E1 con `session_local`, rappresenta il miglior compromesso disponibile per il runtime, ma con evidenza più debole del risultato offline. La terza è che la proiezione SURT

aggiunge leggibilità locale alla metrica offline principale, senza cambiare la conclusione centrale del report.

Nel loro insieme, quindi, i risultati non spostano il baricentro del documento verso le formule event-based. Il primo asse interpretativo resta la soluzione offline come miglior recupero del contrasto D/ND nel campione osservato; il secondo è la soluzione runtime come compromesso causale più sobrio; il terzo è la proiezione SURT come estensione descrittiva della soluzione offline. È questa la gerarchia con cui vanno lette anche le conclusioni operative.

8 Conclusioni operative

8.1 Soluzione offline

Il principale risultato positivo del pilot, in termini di recupero del contrasto D/ND, è la soluzione offline `hr_burden_above_baseline_plus_3bpm` con baseline `first_sessionlower-quartilemedian`. È la combinazione che massimizza il numero di soggetti con $D > ND$, arrivando a 28/42, e rappresenta quindi il miglior esito ottenuto nell'analisi retrospettiva del campione. Tuttavia non è robusta rispetto all'ordine delle sessioni, non raggiunge il target forte 30/40 e non è runtime-ready.

8.2 Soluzione runtime

La migliore soluzione runtime è **E1** con baseline `session_local`, usando la finestra *immediate post* $[0, +10]$ s. Questa combinazione va letta come il miglior compromesso causale e locale oggi disponibile: è meno forte nel conteggio grezzo dei soggetti positivi rispetto alla migliore soluzione offline, ma è molto più equilibrata tra D-first e D-second e quindi più credibile come proxy locale di attivazione per episodi di task. **E3** va mantenuta come formula secondaria, mentre **A2** va conservata solo come benchmark session-level di stato lento, non come indice locale principale.

8.3 Proiezione SURT

La proiezione SURT non introduce una nuova metrica dominante. Mostra che la soluzione offline principale può essere riportata sui log come annotazione derivata coerente con il contrasto globale D/ND, e che la versione `ro1120` offre una lettura locale offline-derived utile per interpretare i task senza modificare i log originali. Va quindi letta come estensione interpretativa della soluzione offline, non come sostituzione del confronto principale fra approcci offline e runtime.

8.4 Limite principale del dataset

Il limite principale è che nessuna combinazione raggiunge 30/40 con robustezza rispetto all'ordine. Molte metriche, incluse alcune fra le più favorevoli offline, collassano nel sottogruppo *D-second*. Di conseguenza il dataset, nello stato attuale, non consente ancora una dimostrazione forte e generalizzabile di separazione D/ND basata su una metrica cardiaca unica. Il quadro più credibile oggi resta quindi questo: una soluzione offline che recupera meglio il contrasto ma

resta order-sensitive, una soluzione runtime più causale ma più debole e una proiezione SURT che aggiunge leggibilità locale senza modificare la conclusione principale.

9 Figure e tabelle

Le tabelle quantitative principali sono riportate nella Sezione 6. Le figure seguenti raccolgono invece il supporto grafico essenziale per leggere in modo coerente i risultati offline e runtime.

9.1 Figure per la soluzione offline




Figura 2: Ranking finale delle combinazioni metrica-baseline secondo il criterio di prevalenza soggettiva $D > ND$, con informazione combinata su interpretabilità, idoneità runtime e sensibilità all'ordine.

Questa figura ordina le combinazioni finali e rende evidente che le prime posizioni sono occupate soprattutto da metriche session-level con ancore di prima sessione. Le soluzioni runtime-ready sono presenti nel ranking, ma non dominano il conteggio grezzo dei soggetti positivi. La figura è rilevante perché mostra visivamente il motivo per cui la migliore soluzione offline non coincide con quella runtime.




Figura 3: Mappa finale delle coppie metrica-baseline, utile a distinguere il contributo della metrica dal contributo della baseline nel risultato conclusivo.

La mappa metrica-baseline mostra che il comportamento di una combinazione non dipende mai soltanto dalla formula, ma dalla coppia completa metrica-riferimento. Passando da una baseline di prima sessione a una baseline locale la stessa famiglia di metriche può cambiare sensibilmente posizione. La rilevanza della figura sta quindi nel rendere concreta l'idea, centrale in questo report, che la baseline è una variabile strutturale e non un semplice parametro accessorio.




Figura 4: Confronto tra famiglie di baseline, riportando per ciascuna la migliore combinazione disponibile e il relativo numero di soggetti con $D > ND$.

Il confronto tra famiglie di baseline conferma che le ancore simmetriche di prima sessione sono

quelle che spingono più in alto il conteggio offline, fino a 27–28 soggetti positivi. Le opzioni `session_local` e `baseline_invariant` restano più in basso, mentre le baseline favorevoli *ND-first* non sono disponibili sull'intero campione e non possono sostenere la conclusione principale. La figura è importante perché mostra che la baseline può migliorare il conteggio, ma non risolve la fragilità rispetto all'ordine.




Figura 5: Scomposizione per ordine delle combinazioni principali: confronto diretto fra sottogruppi D-first e D-second sul criterio $D > ND$.

Questa è probabilmente la figura più importante dell'intera parte offline. La migliore combinazione a posteriori è quasi perfetta nel sottogruppo D-first, ma perde gran parte del vantaggio quando D è la seconda sessione. La figura è quindi il supporto grafico più chiaro per affermare che la soluzione offline è utile ma fortemente order-sensitive.

9.2 Figure per la soluzione runtime




Figura 6: Confronto fra formule locali/event-based e benchmark session-level, con enfasi sulla separazione tra descrittori di transient effects e metriche di stato lento.

Questa figura mette a confronto le formule locali candidate e chiarisce perché il benchmark session-level A2 non possa essere considerato la scelta migliore per gli effetti transitori. E1 ed E3 emergono come le opzioni locali più utilizzabili nella sola prospettiva runtime, mentre E2 ed E4 restano più deboli o più instabili. La figura è rilevante perché aiuta a leggere il compromesso runtime, senza spostare il baricentro rispetto al risultato offline principale.




Figura 7: Confronto pre/post evento per la formula locale selezionata, focalizzato sulla risposta immediata attorno agli episodi di task.

Il grafico pre/post della formula migliore evidenzia un effetto locale piccolo e rumoroso, con ampia sovrapposizione tra i casi. Questo aspetto è importante perché impedisce di sopravvalu-

tare l'entità del risultato: il segnale esiste come tendenza debole, non come separazione netta soggetto per soggetto. La figura giustifica quindi il linguaggio prudente del report, che parla di proxy locale di attivazione e non di misura validata di arousal.




Figura 8: Posizionamento delle formule locali in funzione di interpretabilità e robustezza empirica, con evidenza della formula raccomandata e dell'alternativa secondaria.

Il posizionamento delle formule locali rende evidente il compromesso che guida la scelta finale. E1 occupa la posizione più convincente quando si combinano interpretabilità alta, computabilità online e buona tenuta all'ordine; E3 rimane molto vicina ma è leggermente meno immediata da spiegare. La figura è utile perché visualizza il motivo per cui la scelta runtime non dipende solo dal punteggio empirico, ma anche dalla trasparenza del costrutto, restando comunque un asse secondario rispetto al risultato offline.




Figura 9: Confronto tra finestre temporali locali, con distinzione tra finestra immediata post-evento, finestra ritardata e finestra durante-evento.

Il confronto tra finestre temporali mostra che la finestra $[0, +10]$ s non è quella con l'effetto numericamente più alto in assoluto, ma è la migliore combinazione fra causalità, tempestività e confrontabilità. La finestra *during* produce una media interna più grande, ma usa durate di evento variabili e quindi riduce la confrontabilità tra soggetti. La figura supporta quindi la raccomandazione pratica di mantenere la finestra *immediate post* come scelta standard.




Figura 10: Prestazioni delle formule locali separate per ordine di sessione, con attenzione ai casi di attenuazione e inversione nel sottogruppo D-second.

La scomposizione per ordine conferma che E1 ed E3 non collassano in modo marcato quando D è la seconda sessione: il segnale si attenua verso la neutralità ma non inverte nettamente come accade per E2. E4 resta invece negativa in entrambi i sottogruppi. Questa figura è rilevante

perché rende intuitivo il motivo per cui E1 sia oggi la formula runtime più credibile, pur restando un risultato secondario rispetto al recupero offline del contrasto.

9.3 Figura per la proiezione SURT




Figura 11: Proiezione della metrica offline `hr_burden_above_baseline_plus_3bpm` con baseline `first-sessionlower-quartilemedian` sui log SURT: confronto del burden a livello di sessione fra condizioni, paired plot D vs ND, scomposizione per ordine, distribuzione row-level della annotazione locale `roll20`, confronto pre/post evento e associazione con i tempi di risposta SURT.

I sei pannelli leggono la stessa proiezione da prospettive complementari. I pannelli sul burden di sessione e sul paired plot mostrano che il contrasto D/ND della metrica offline si conserva quando viene riportato nel contesto SURT; la scomposizione per ordine conferma però che il vantaggio resta concentrato in *D-first*. La distribuzione row-level del `roll20` indica un livello locale mediamente più alto in D, mentre il confronto pre/post segnala che l'effetto strettamente agganciato al singolo evento è molto piccolo. Il pannello sulla relazione con `ResponseTime_ms` completa il quadro mostrando che il legame con la performance esiste, se esiste, in forma debole e poco strutturata.

9.4 Commento interpretativo dei risultati

I risultati ottenuti suggeriscono che il contrasto tra condizioni D e ND non dipende soltanto dalla presenza del task di distrazione, ma è fortemente modulato da fattori sperimentali e strumentali che agiscono sul segnale cardiaco osservato. In particolare, l'effetto dell'ordine delle sessioni, la natura breve e intermittente dei task, l'assenza della baseline originaria di calibrazione e i limiti del sensore Coospo costituiscono spiegazioni plausibili del fatto che nessuna metrica abbia prodotto una separazione forte e robusta tra D e ND sull'intero campione.

Una spiegazione plausibile dell'effetto ordine riguarda la fase di familiarizzazione al simulatore. Prima delle sessioni sperimentali vere e proprie ogni soggetto ha svolto una breve familiarizzazione di circa due minuti; tuttavia, è ragionevole ipotizzare che tale durata non sia stata sufficiente a stabilizzare in modo uniforme l'adattamento al simulatore per tutti i partecipanti. L'efficacia della familiarizzazione può infatti dipendere in modo marcato dalle differenze individuali: alcuni soggetti possono raggiungere rapidamente una condizione relativamente stabile, mentre altri possono mantenere più a lungo una quota residua di attivazione aspecifica, legata alla novità dell'ambiente, alla coordinazione con i controlli o alla necessità di adattarsi alla dinamica del simulatore. In questa prospettiva, l'ordine delle sessioni non agisce necessariamente come semplice variabile organizzativa, ma come fattore che può modulare il livello fisiologico di partenza con cui il soggetto affronta la condizione D o ND.

Questo significa che una parte del contrasto osservato tra D e ND può riflettere non solo l'effetto della distrazione, ma anche una diversa fase di adattamento residuo al simulatore, variabile da soggetto a soggetto. Tale interpretazione è coerente con il fatto che diverse metriche mostrino risultati molto favorevoli nel sottogruppo *D-first* ma perdano gran parte del vantaggio in *D-second*: una parte del segnale recuperato sembra quindi associata non soltanto alla condizione sperimentale, ma anche alla posizione temporale con cui la sessione viene affrontata nel protocollo. Naturalmente questa resta un'interpretazione plausibile e non una dimostrazione causale diretta; tuttavia offre una spiegazione coerente del fatto che l'ordine delle sessioni continui a incidere anche in presenza di una breve fase preliminare di familiarizzazione.

Una seconda spiegazione riguarda la natura del task di distrazione utilizzato. Il compito sperimentale, consistente nell'interazione con puntini rossi su uno schermo laterale, introduce certamente una componente di competizione attentiva e di carico cognitivo, ma lo fa attraverso episodi relativamente brevi e intermittenti. Una risposta cardiovascolare osservabile tramite il solo HR non è necessariamente istantanea né di grande ampiezza: anche in presenza di un aumento reale del carico mentale, l'effetto sull'HR può svilupparsi su una scala di alcuni secondi e risultare attenuato se il task è molto corto, frammentato o alternato rapidamente a fasi di guida ordinaria. Ne consegue che il task può peggiorare la qualità della guida o aumentare il carico cognitivo senza produrre sempre una variazione sufficientemente netta dell'HR medio da separare in modo robusto le due condizioni a livello di sessione.

Questa osservazione aiuta anche a interpretare il fatto che le formule event-based risultino più promettenti delle metriche puramente session-level. Se l'effetto fisiologico del task è locale e transitorio, una metrica che media l'intera sessione rischia di diluirlo fino quasi a farlo scomparire. Al contrario, un indice costruito su finestre pre/post evento, come E1, è metodologicamente più adatto a catturare variazioni deboli ma temporalmente concentrate. Il fatto che anche queste formule mostrino effetti piccoli e rumorosi suggerisce però che il problema non sia soltanto nella scelta della formula, ma anche nella scala temporale e nell'intensità del fenomeno che si sta tentando di osservare.

Un terzo elemento interpretativo riguarda le caratteristiche del sensore Coospo e della catena di misura disponibile. Il Coospo fornisce una misura HR utile per analisi esplorative e per il monitoraggio generale del livello cardiaco, ma è meno adatto di una fascia toracica o di un ECG a catturare variazioni fisiologiche molto fini e transitorie. Nel dataset disponibile, inoltre, la componente RR non è stata osservata in modo sufficientemente continuo e robusto, soprattutto in presenza di movimento del braccio, e questo ha impedito di usare in modo affidabile indici HRV più sensibili all'attivazione simpatica. Di conseguenza l'analisi è stata costretta a basarsi soprattutto su metriche HR-derived trasparenti, che sono più spiegabili ma anche meno ricche sul piano fisiologico rispetto a una misura completa di variabilità cardiaca.

A questo si aggiunge un possibile effetto di latenza e attenuazione nella misura del segnale. Se il segnale HR è campionato o aggregato in modo tale da non essere perfettamente allineato all'inizio del task, una parte della risposta locale può essere persa o mediata insieme a campioni non direttamente legati all'episodio di distrazione. In termini pratici, un task breve può generare un incremento reale ma modesto dell'attivazione, mentre la metrica osservata dal sensore riflette una media locale che ingloba anche fasi di transizione o di ritorno al livello di base. Questo contribuisce a spiegare perché la finestra *immediate post* risulti più utile delle analisi puramente globali, ma anche perché l'effetto resti debole in termini assoluti.

Va considerata anche la possibilità che il task di distrazione non induca sempre uno stress fisiologico nel senso stretto del termine, ma piuttosto un aumento del carico cognitivo o della competizione attentiva. Queste dimensioni possono peggiorare la prestazione o aumentare l'instabilità di guida senza produrre necessariamente un incremento cardiaco uniforme in tutti i soggetti. Alcuni guidatori possono reagire con aumento dell'HR, altri con strategie compensative più prudenti, altri ancora con una risposta fisiologica minima ma con maggiore degrado prestazionale. Questo rende plausibile una forte eterogeneità individuale, coerente con il fatto che il segno del delta $D-ND$ non sia uniforme su tutto il campione.

Anche la costruzione della baseline incide direttamente sull'esito finale. Le baseline ancorate alla prima sessione conservano meglio la differenza globale tra sessioni, ma proprio per questo trattengono anche una quota dell'effetto di novità o di adattamento iniziale. Le baseline locali di sessione, al contrario, sono più corrette per un uso causale e runtime, ma tendono ad assorbire parte del drift lento e a ridurre il contrasto complessivo. Il fatto che il numero di soggetti con $D > ND$ cambi sensibilmente al variare della baseline indica che il problema non riguarda solo la formula di attivazione, ma anche il riferimento rispetto a cui tale attivazione viene misurata.

Infine, non va escluso che una parte della variabilità residua derivi dal contesto di guida e dalla sua interazione con i task. Sebbene P1 e P2 non rappresentino le condizioni sperimentali, restano percorsi diversi e possono introdurre differenze di carico visuo-motorio, stabilità della traiettoria, richiesta di controllo e distribuzione temporale degli eventi. Anche piccoli disallineamenti tra task, dinamica di guida e stato del soggetto possono tradursi in una forte dispersione delle metriche fisiologiche finali.

Nel complesso, questi risultati sono coerenti con una lettura prudente. Il dataset suggerisce la presenza di un segnale di attivazione, ma tale segnale appare debole, fortemente modulato dall'ordine delle sessioni e solo parzialmente osservabile attraverso HR medio o sue trasformazioni semplici. Per questo motivo, la soluzione offline migliore e la soluzione runtime migliore non coincidono. La prima massimizza il contrasto retrospettivo a prezzo di una forte sensibilità all'ordine; la seconda rinuncia a parte del contrasto ma risulta metodologicamente più difendibile per un uso causale e in tempo reale.

Un miglioramento metodologico naturale per campagne future consiste nel registrare e salvare esplicitamente la baseline di calibrazione iniziale, sincronizzare con precisione i timestamp dei task e affiancare al Coospo un sensore più adatto alla stima continua degli intervalli RR. In questo modo sarebbe possibile verificare se una misura HRV-based, o una combinazione multimodale fra HR, segnali facciali e comportamento di guida, permetta di recuperare un contrasto D/ND più robusto di quello osservato nel presente pilot.